신경망 구조

김영욱

Hello AI

퍼셉트론

- 인공신경망의 한 종류
- 다수의 입력($x_1, x_2, \ldots, x_n$)과 가중치($w_1, w_2, \ldots, w_n$)를 곱하여 그 값에 편향($bias$)을 더한 값이 어느 임계치 값(θ)을 초과하면 활성화 함수를 통과

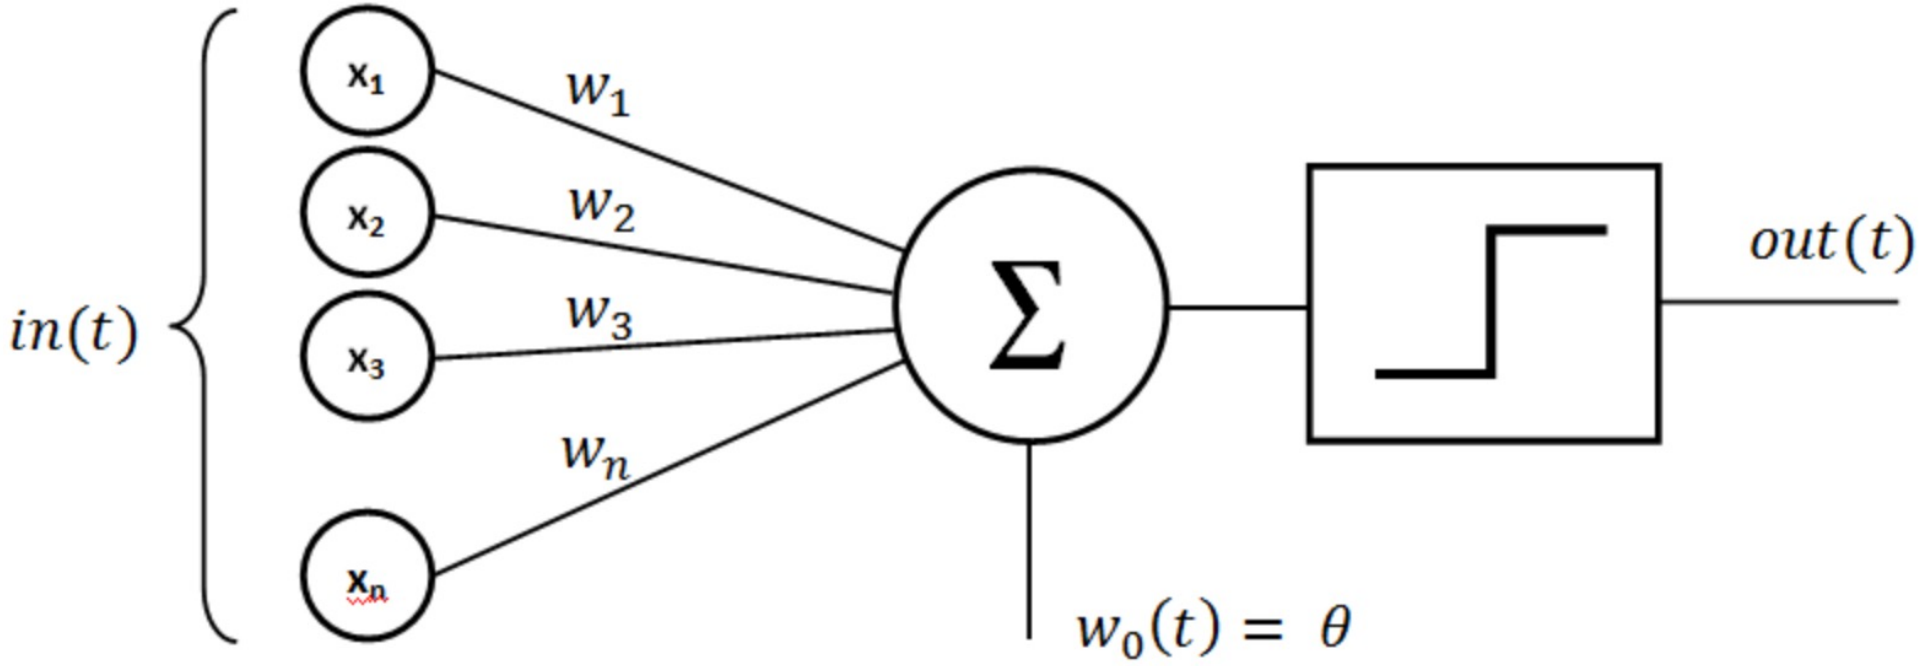

한 출력값을 내보냄

출처: https://towardsdatascience.com/rosenblatts-perceptron-the-very-first-neural-network-37a3ec09038a

뉴런의 수학적 표현

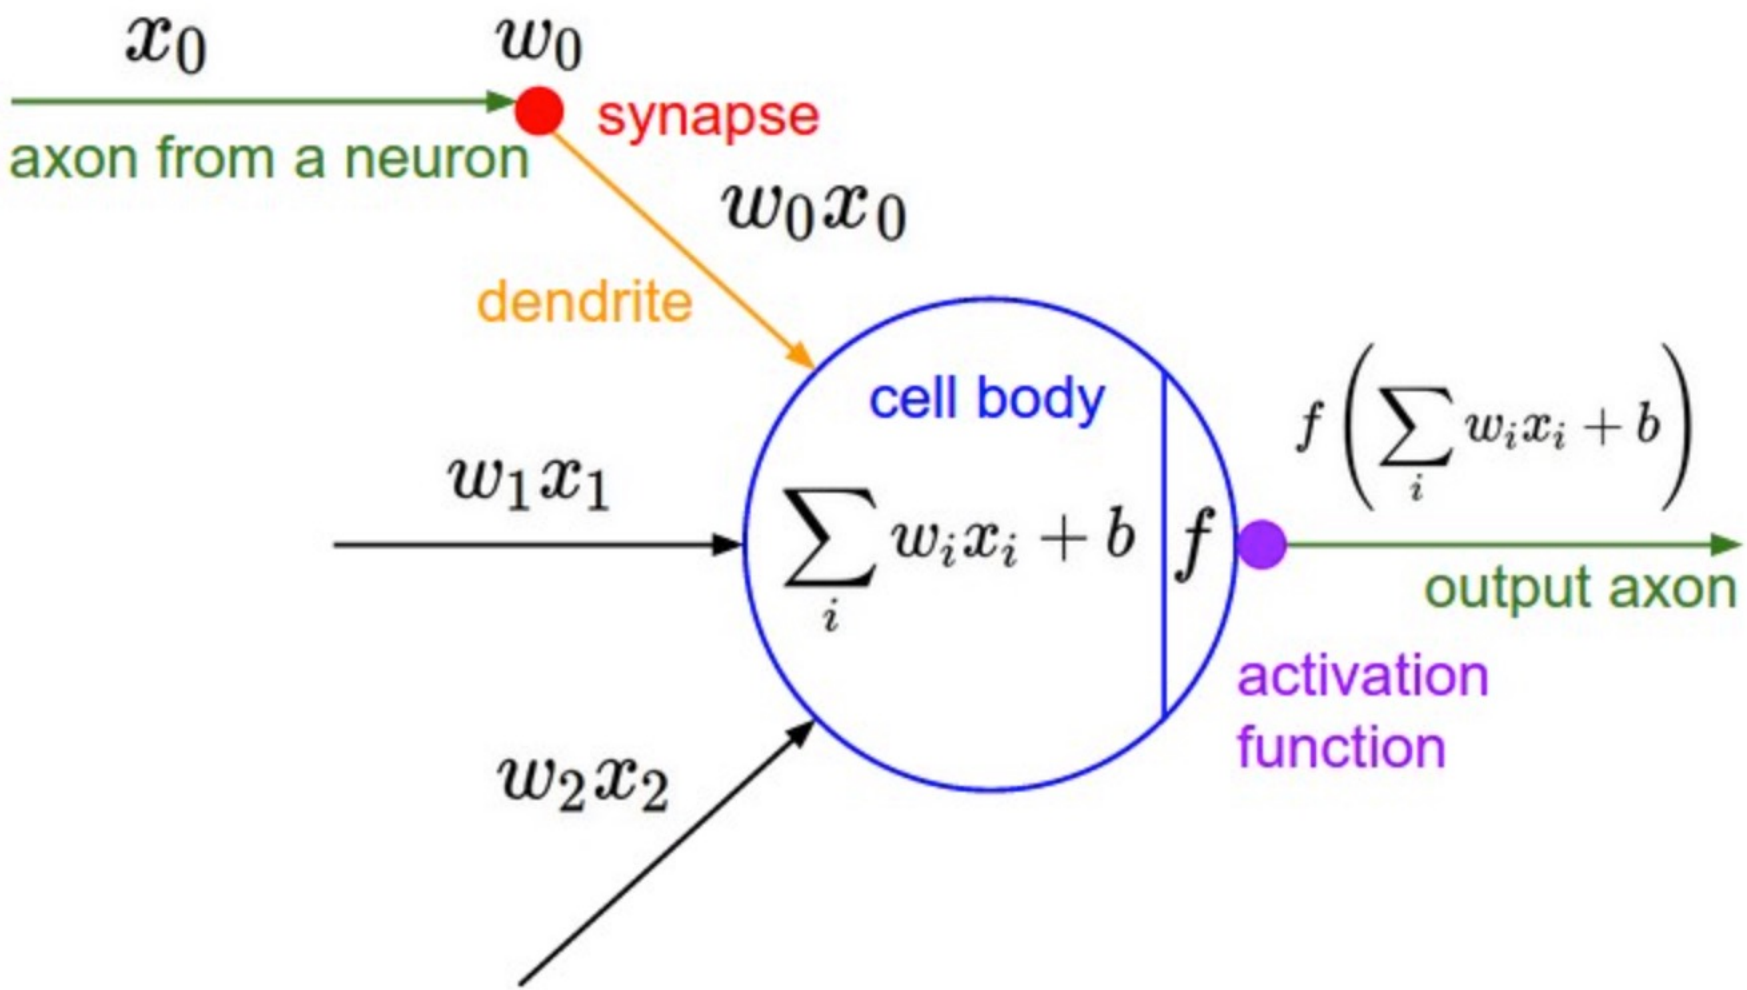

출처: https://cs231n.github.io/convolutional-networks/

$$y = f(\sum_i w_i x_i + b)$$

- f : 활성화 함수
  - 임계값(θ)을 경계로 출력이 바뀜
- b : 편향
  - 결정 경계선을 원점에서부터 벗어나게 해줌
  - 따로 표현이 없어도 기본적으로 존재한다고 생각
- $\sum_i w_i x_i$: 두 벡터의 내적으로 표현 가능

$$x_1 w_1 + x_2 w_2 + \ \ldots \ + x_n w_n = w^T x$$

완전 연결 계층(Fully-Connected Layer) 수학적 표현

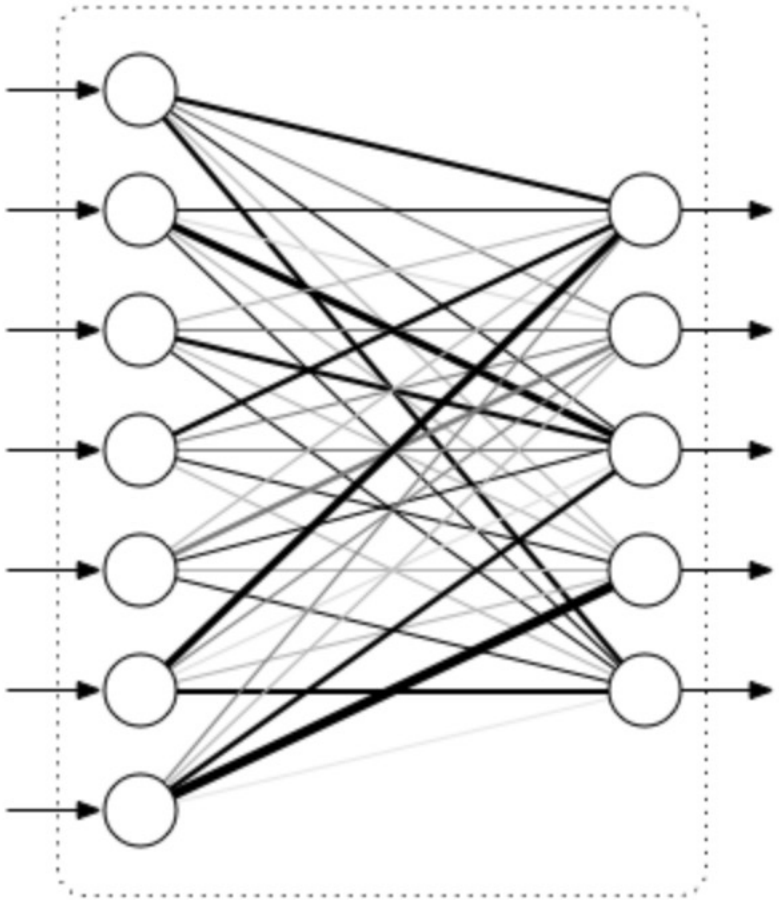

$$W = [w_0, w_1, \ldots, w_{M-1}]^T$$

각각의 w_k는 $N \times 1$ 형태의 벡터

W는 $N \times M$ 행렬

$$b = [b_0, b_1, \ldots, b_{M-1}]$$

$$y_0 = f(w_0^T x + b_0)$$

$$y_1 = f(w_1^T x + b_1)$$

$$y_2 = f(w_2^T x + b_2)$$

$$\ldots$$

$$y_{M-1} = f(w_{M-1}^T x + b_{M-1})$$

$$\rightarrow y = f(Wx + b)$$

논리회로

- 논리 게이트(Logic Gates)
  - AND
  - OR
  - NOT
  - NAND
  - NOR

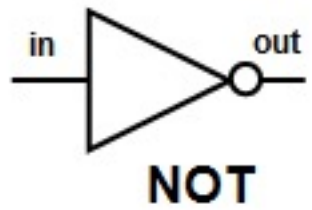

NOT

Input	Output
I	F
0	1
1	0

AND

Inputs		Output
A	B	F
0	0	0
1	0	0
0	1	0
1	1	1

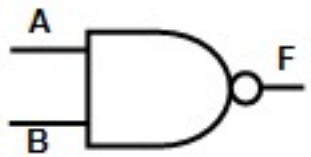

NAND

Inputs		Output
A	B	F
0	0	1
1	0	1
0	1	1
1	1	0

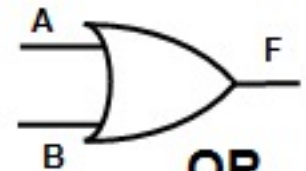

OR

Inputs		Output
A	B	F
0	0	0
1	0	1
0	1	1
1	1	1

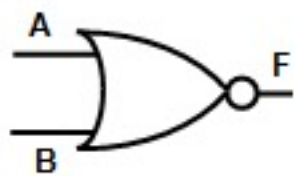

NOR

Inputs		Output
A	B	F
0	0	1
1	0	0
0	1	0
1	1	0

다층 퍼셉트론(Multi Layer Perceptron, MLP)

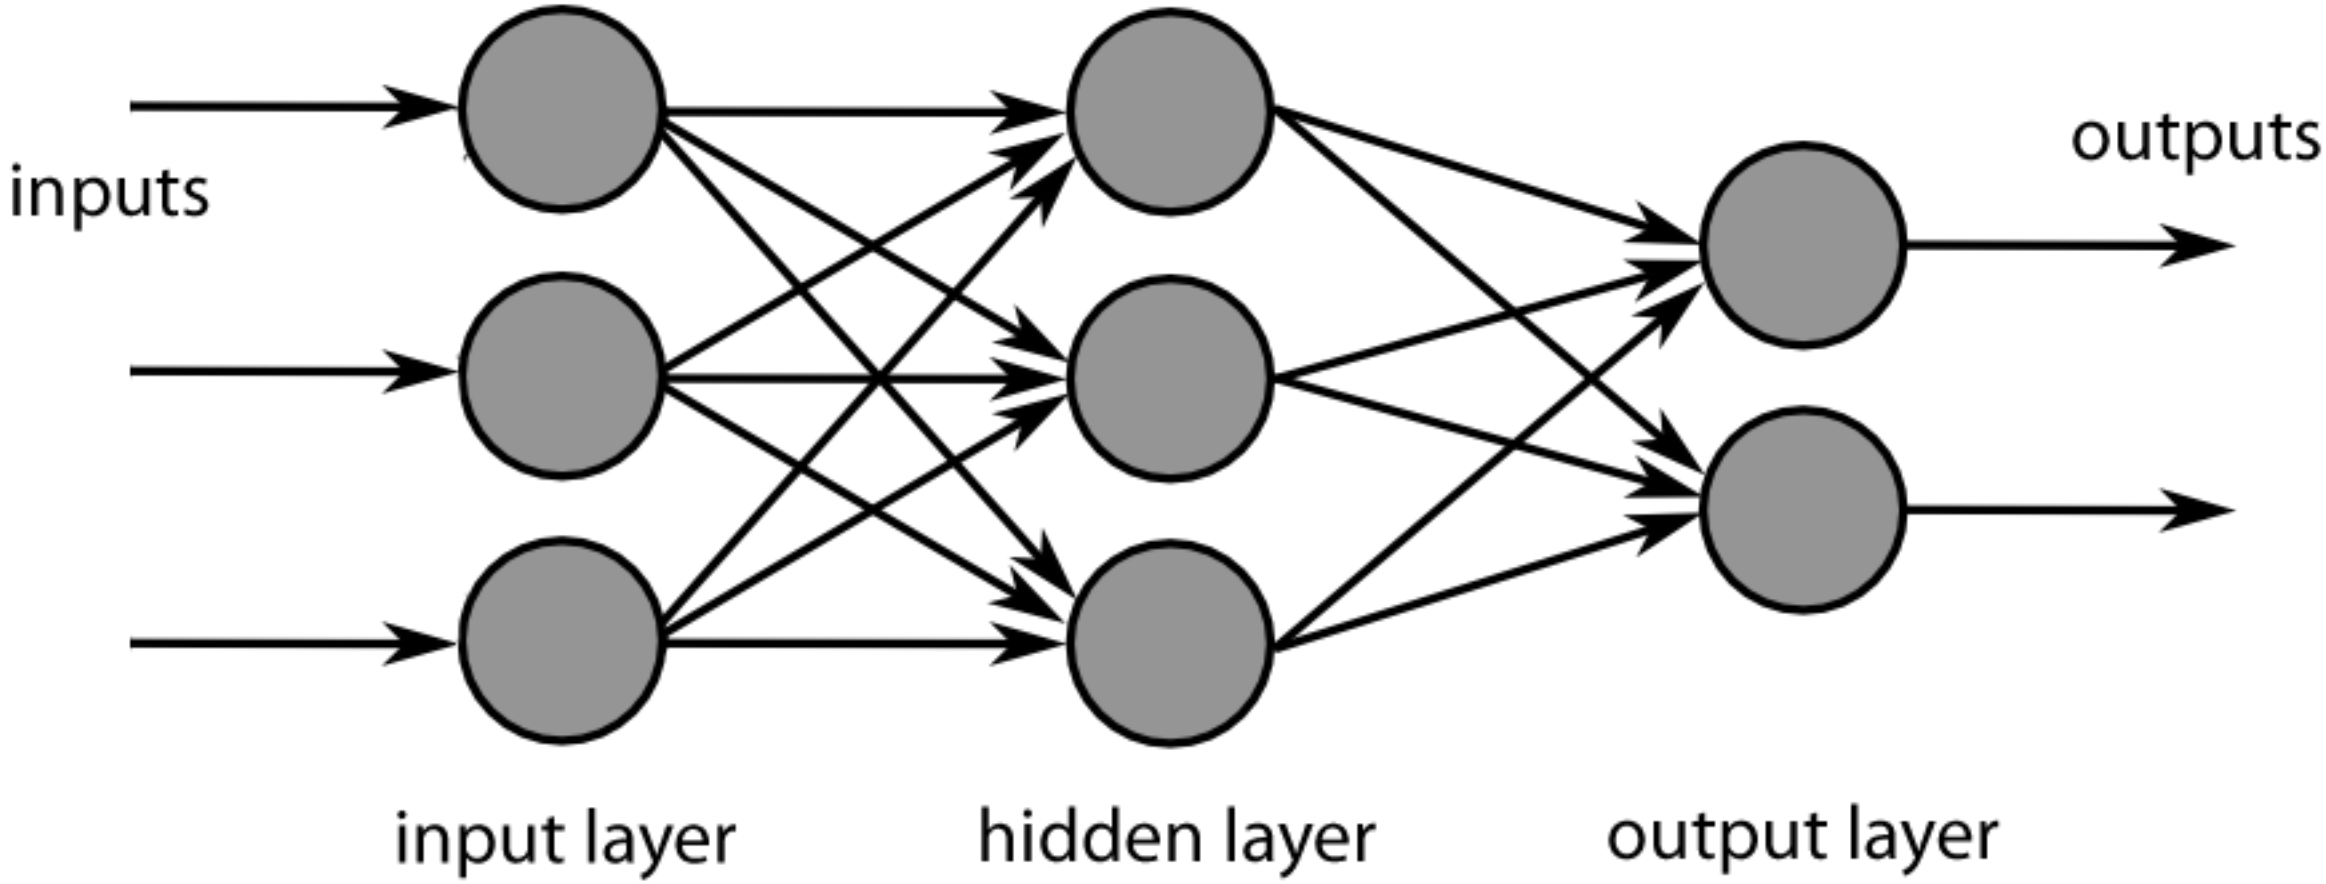

다층 퍼셉트론의 구성
•입력층(input layer)
•은닉층(hidden layer)
- 1개 이상 존재
- 보통 5개 이상 존재하면 Deep Neural Network라고 칭함

•출력층(output layer)

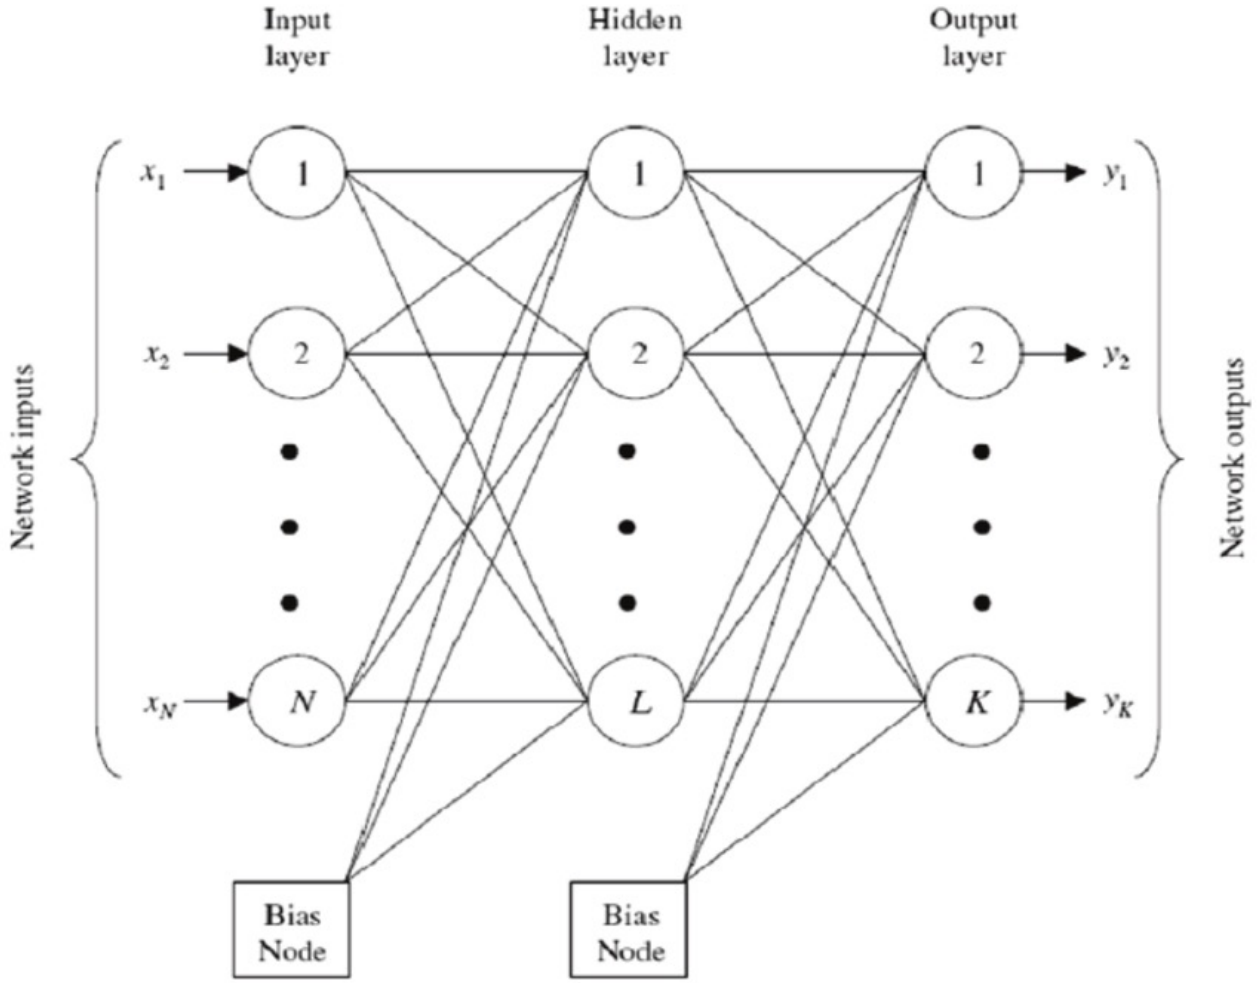

- 수식
  - (input layer → hidden layer)

$$z = f_L(W_L x + b_L)$$

  - (hidden layer → output layer)

$$y = a_K(W_K z + b_K)$$

XOR 게이트

- 서로 다른 두 값이 입력으로 들어가면 1을 반환
- 진리표

Inputs		Output
A	B	A ⊕ B
0	0	0
0	1	1
1	0	1
1	1	0

순환 신경망(Recurrent Neural Network, RNN)

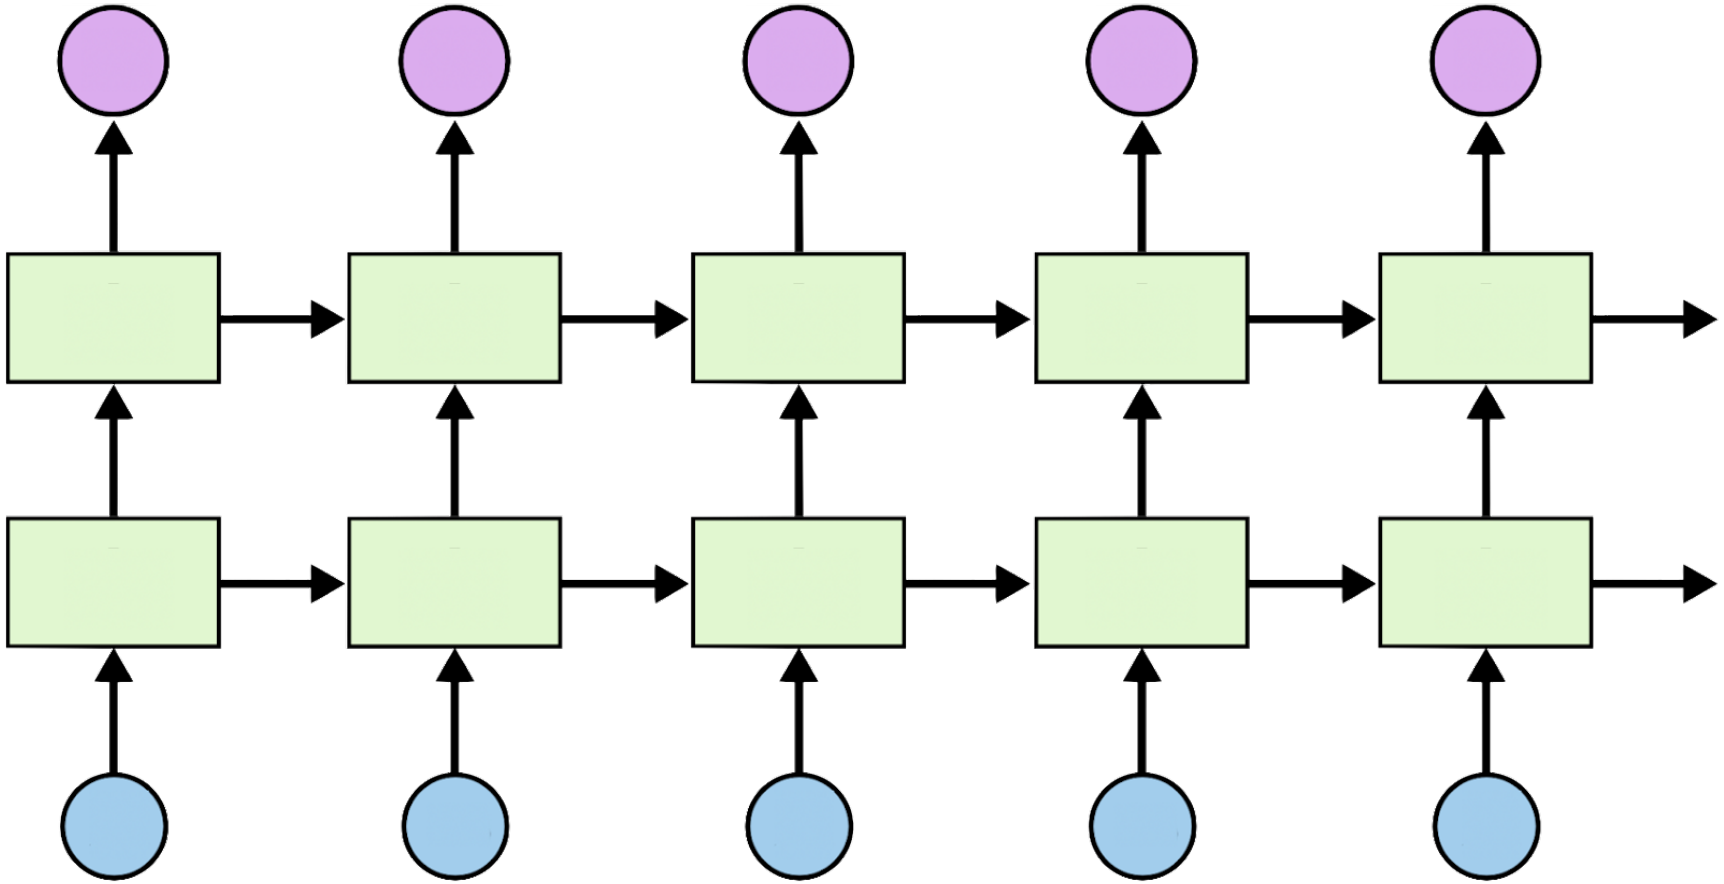

합성곱 신경망(Convolutional Neural Network, CNN)

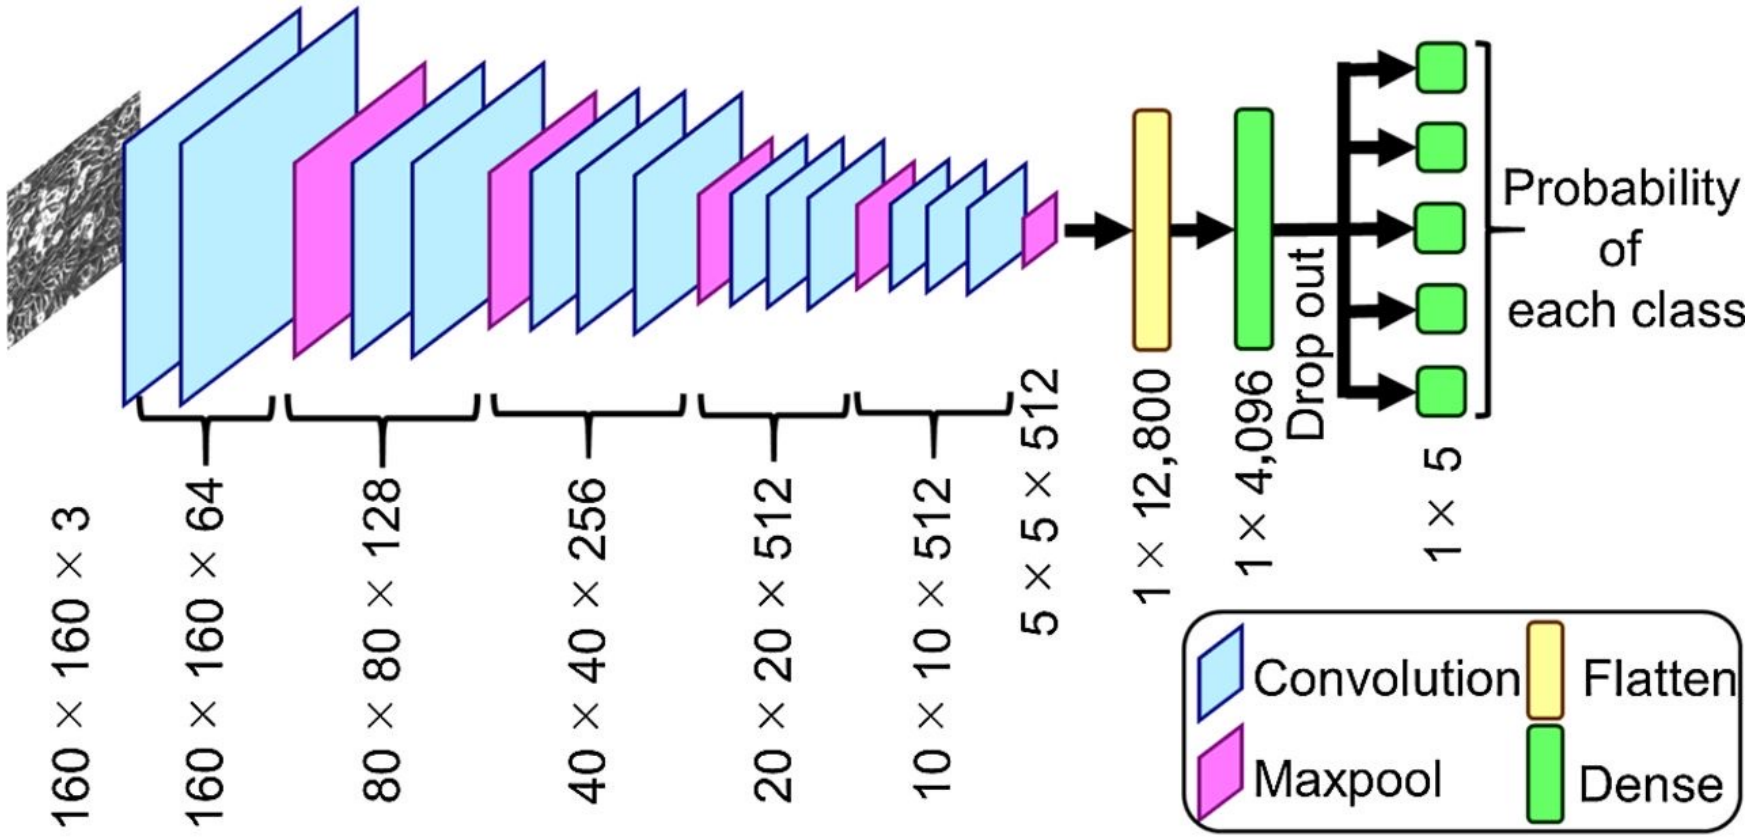

활성화 함수(Activation Function)

- 입력 신호의 총합을 출력 신호로 변환하는 함수
- 활성화 함수에 따라 출력값이 결정
- 단층, 다층 퍼셉트론 모두 사용
- 대표적인 활성화 함수
    - Sigmoid
    - ReLU
    - tanh
    - Identity Function
    - Softmax
- 하나의 layer에서 다음 layer로 넘어갈 때는 항상 활성화 함수를 통과
- [참고] 여러가지 활성화 함수

Step Function(계단 함수)

$$y = \begin{cases} 0 & (x < 0) \\ 1 & (x \geq 0) \end{cases}$$

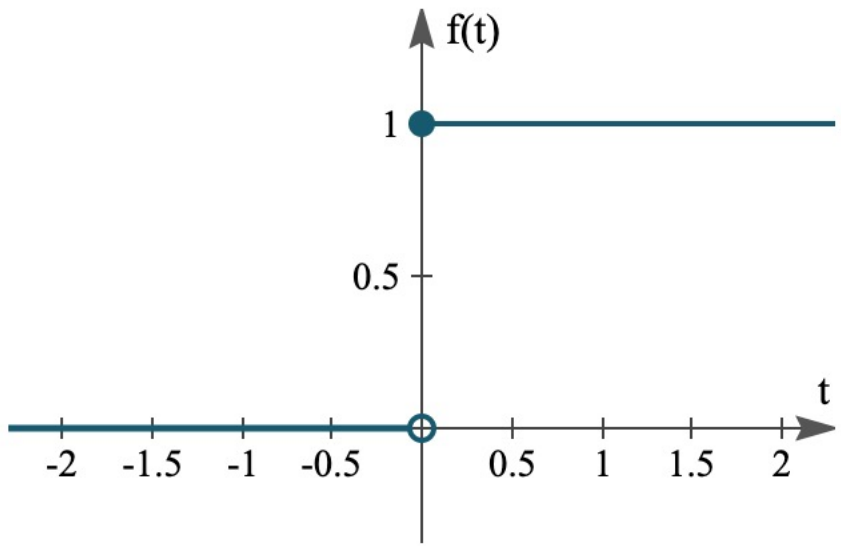

출처: https://www.intmath.com/laplace-transformation/1a-unit-step-functions-definition.php

Sigmoid Function(시그모이드 함수)

- 이진분류(binary classification)에 주로 사용
    - 마지막 출력층의 활성화 함수로 사용
- 출력값이 0~1 의 값이며, 이는 **확률**로 표현 가능

$$y = \frac{1}{1+e^{-x}}$$

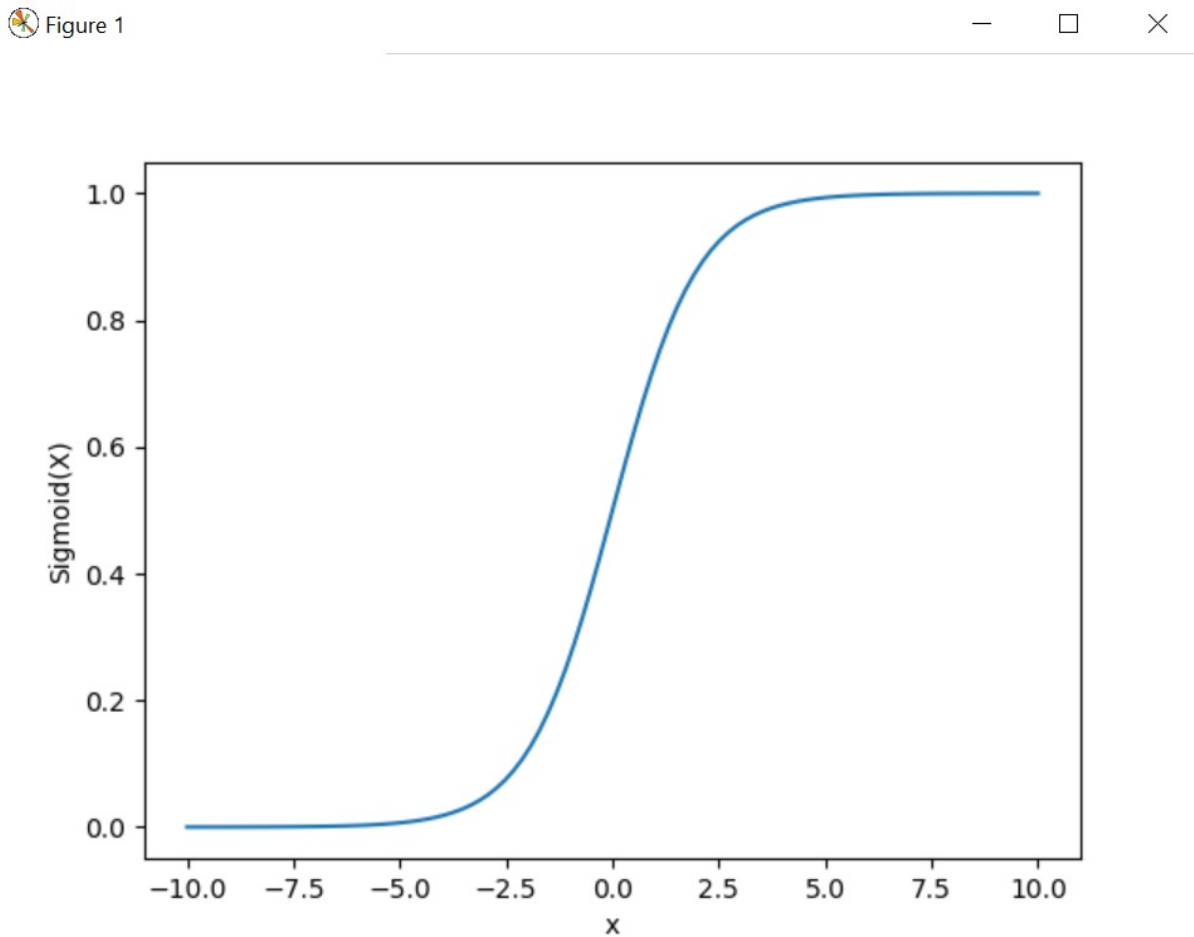

ReLU(Rectified Linear Unit)

- 가장 많이 쓰이는 함수 중 하나

$$y = \begin{cases} 0 & (x \leq 0) \\ x & (x > 0) \end{cases}$$

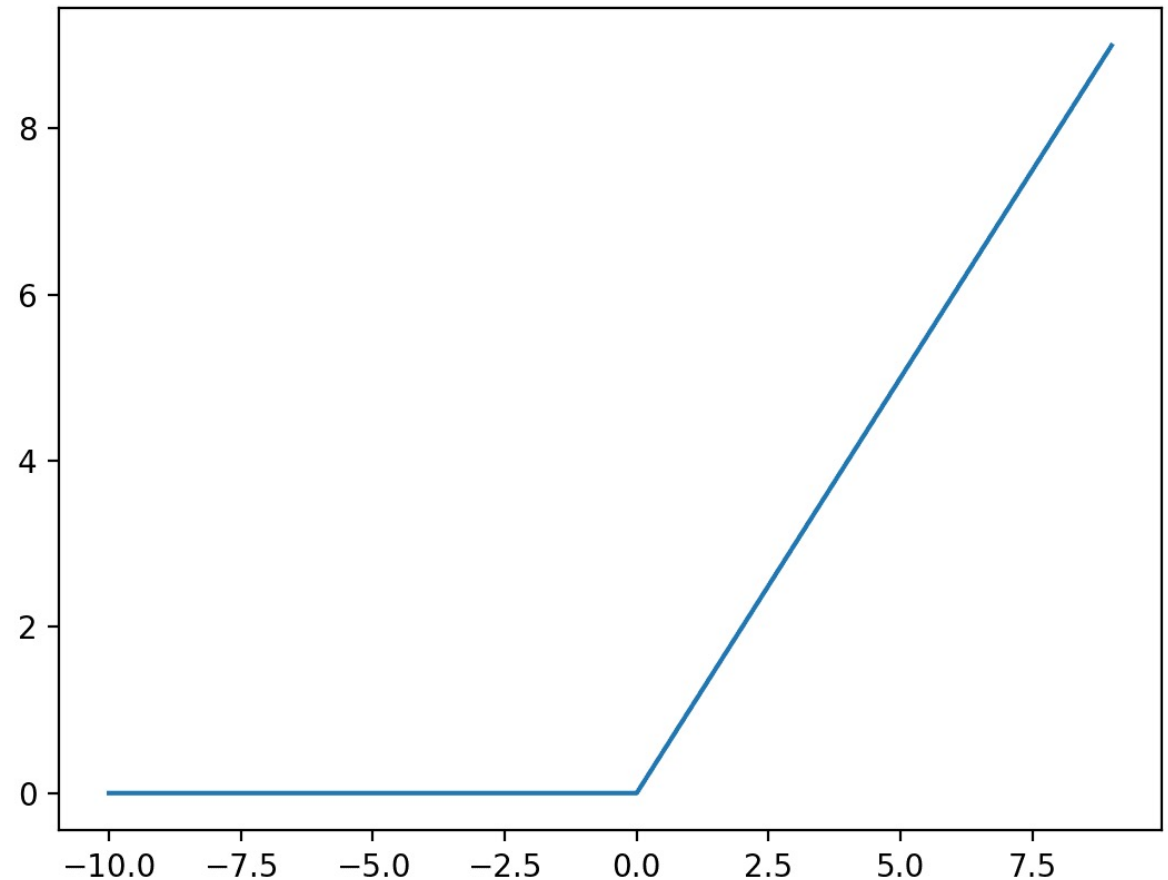

Identity Function(항등 함수)

- 회귀(Regression) 문제에서 주로 사용
    - 출력층의 활성화 함수로 활용
- $y = x$
- 입력값 그대로 출력하기 때문에 굳이 정의할 필요는 없지만 신경망 중간 레이어 흐름과 통일하기 위해 사용

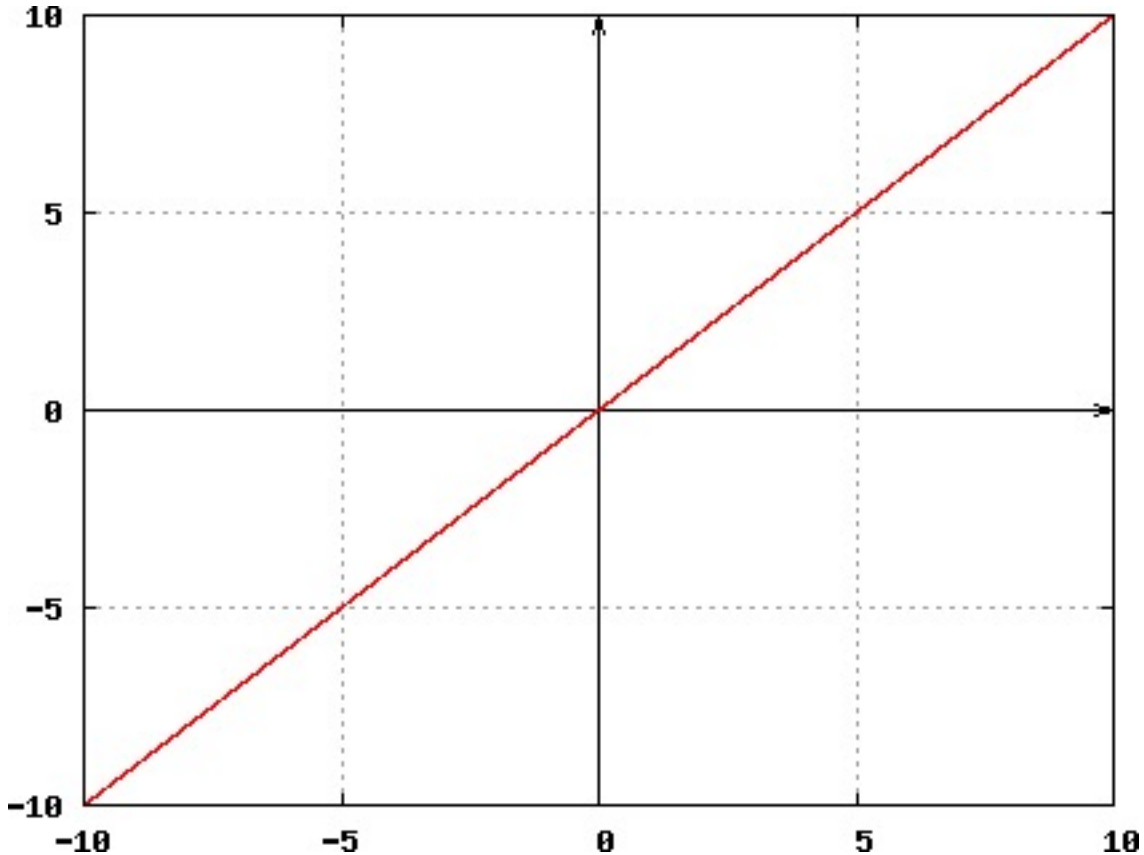

Softmax

- 다중 클래스 분류에 사용(Multi Class Classification)
- 입력값의 영향을 크게 받음
  입력값이 크면 출력값도 큼
- 출력값을 확률에 대응가능
- 출력값의 **총합은 1**
- 수식

$$y_k = \frac{exp(a_k)}{\sum_{i=1} exp(a_i)}$$

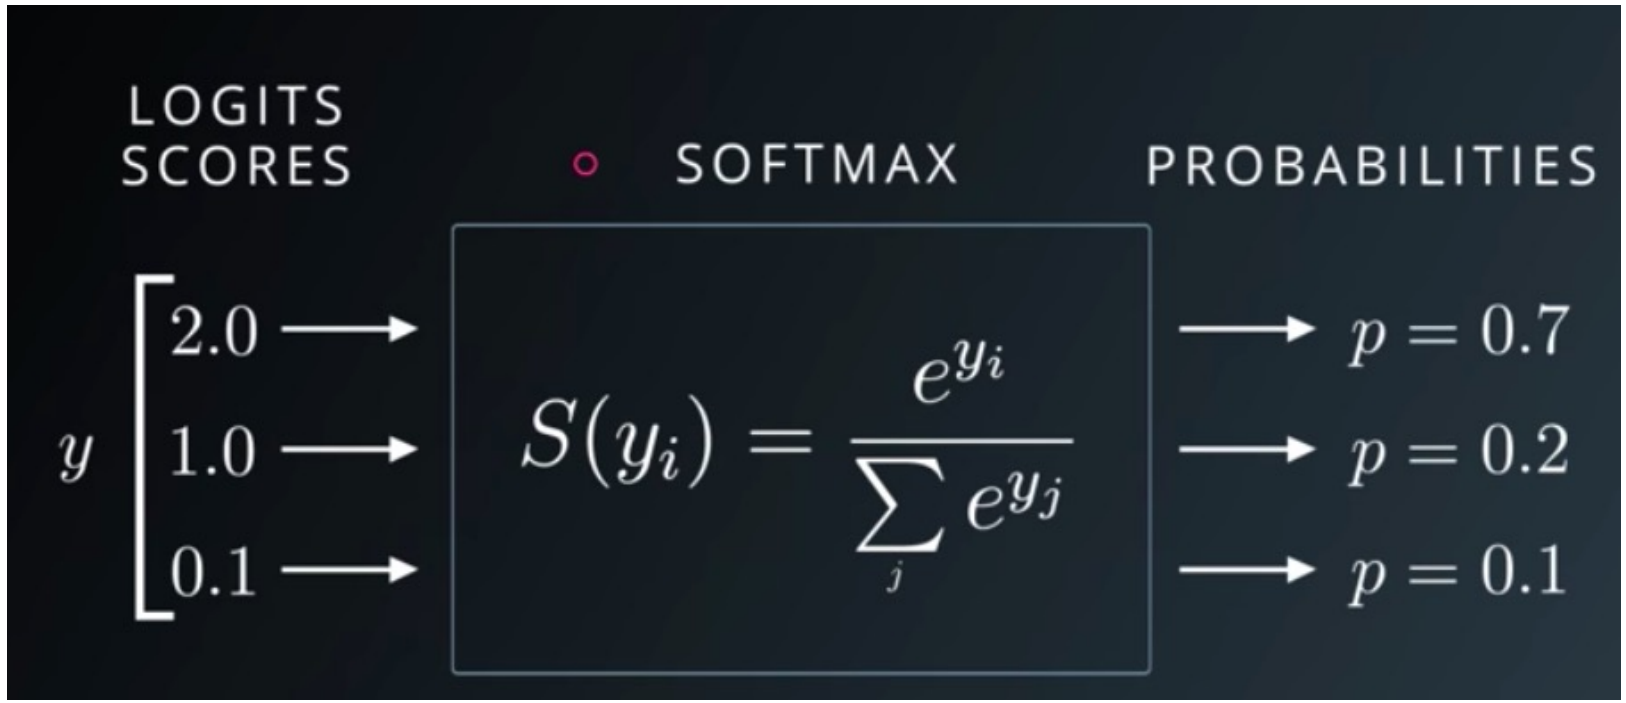

소프트맥스 함수 주의점

- 오버플로우(overflow) 문제
- 지수함수(exponential function)을 사용하기 때문에 입력값이 너무 크면 무한대(inf)가 반환됨
- 개선한 수식

$$y_k = \frac{exp(a_k)}{\sum_{i=1} exp(a_i)} = \frac{Cexp(a_k)}{C\sum_{i=1} exp(a_i)}$$

$$= \frac{exp(a_k + logC)}{\sum_{i=1} exp(a_i + logC)}$$

$$= \frac{exp(a_k + C')}{\sum_{i=1} exp(a_i + C')}$$

활성화 함수를 비선형 함수(non-linear function)로 사용하는 이유

- 신경망을 깊게(deep) 하기 위함
- 만약 활성화 함수를 선형함수(linear function)으로 하게 되면 은닉층의 갯수가 여러개이더라도 의미가 없어짐
- 만약, $h(x) = cx$이고, 3개의은닉층이존재한다면

$$
\begin{aligned}
y &= h(h(h(x))) \\
&= c * c * c * x \\
&= c^3 x
\end{aligned}
$$

이므로 결국에는 선형함수가 되어버림

그 외의 활성화 함수

- LeakyReLU

$$f_a(x) = \begin{cases} x & (x \geq 0) \\ ax & (x < 0) \end{cases}$$

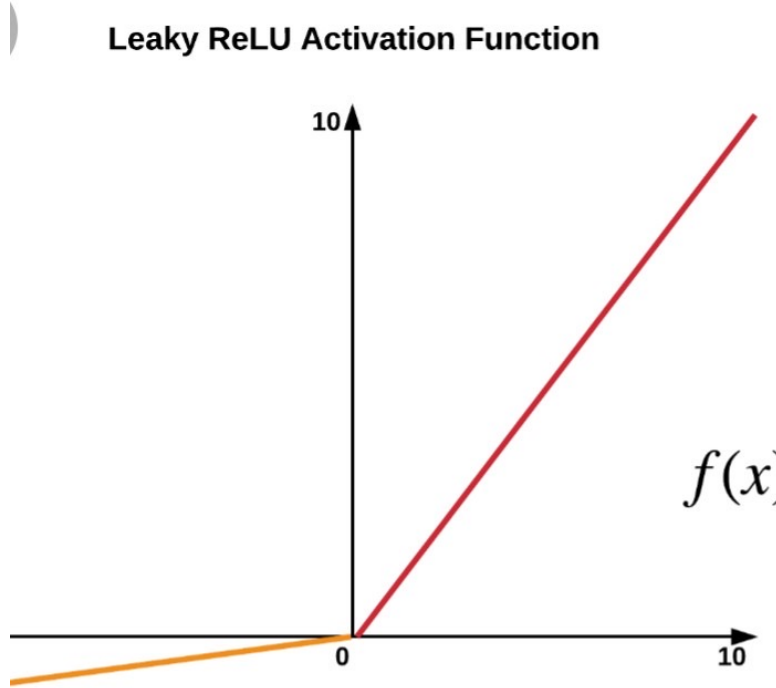

$$f(x) = \begin{cases} 0.01x & \text{for x} < 0 \\ x & \text{for x} \geq 0 \end{cases}$$

ELU(Exponential Linear Units)

$$f(\alpha, x) = \begin{cases} \alpha\,(e^x - 1) & (x \leq 0) \\ x & (x > 0) \end{cases}$$

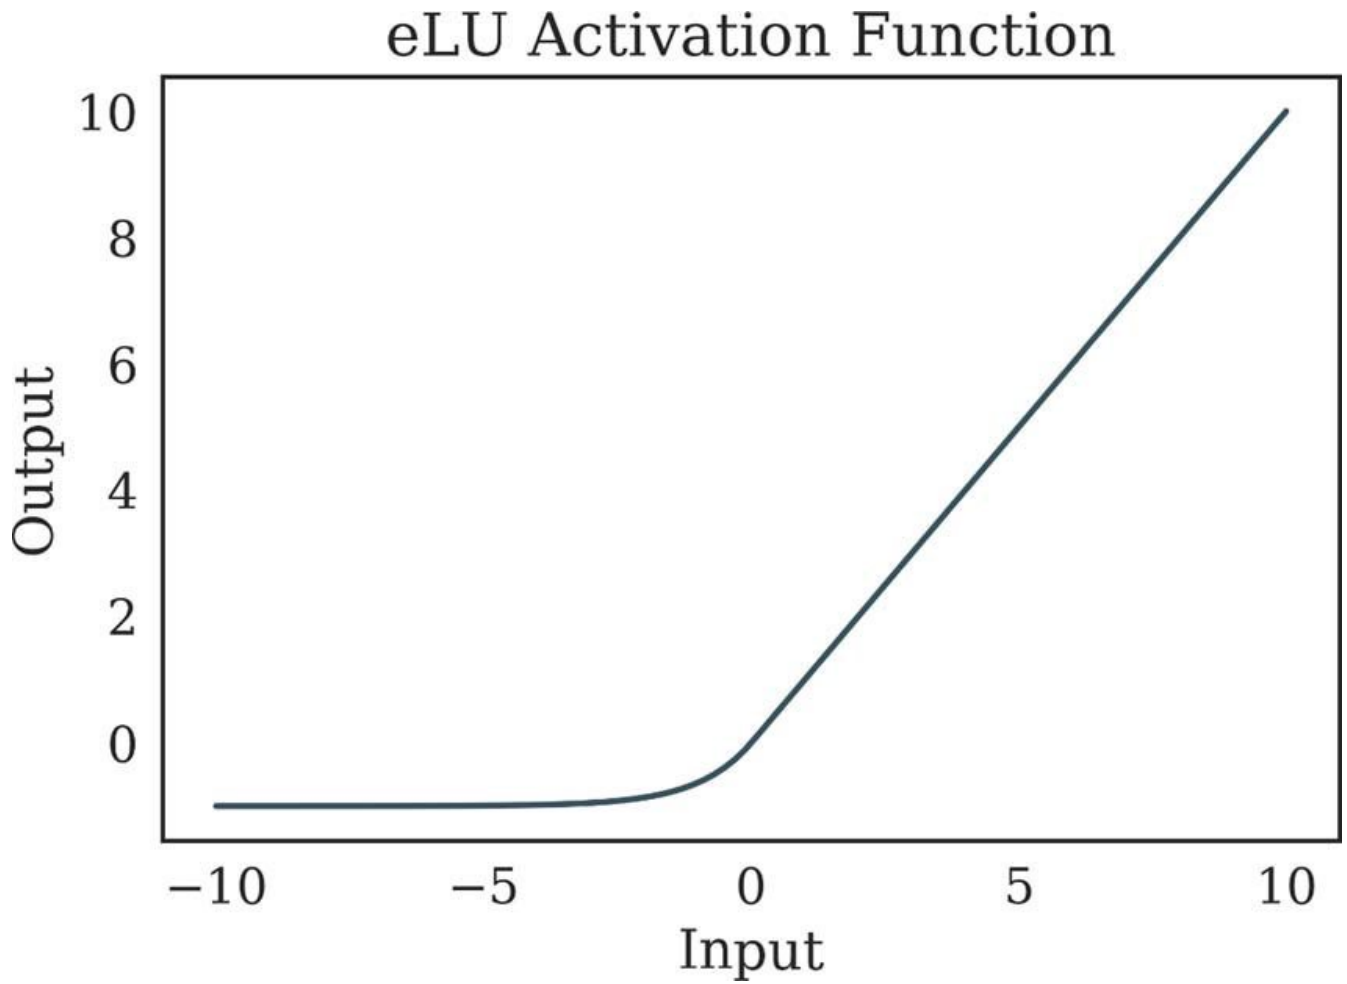

3층 신경망 구현하기

- 2클래스 분류
- 입력층(Input Layer)
    - 뉴런수: 3
- 은닉층(Hidden Layers)
    - 첫번째 은닉층
        - 뉴런수: 3
    - 두번째 은닉층
        - 뉴런수: 2
- 출력층(Output Layer)
    - 뉴런수: 2